01 Задача и данные

Рекомендательная система для медиакаталога

Кузнецов Станислав · АСУ8-25-1м

Задача. Построить рекомендательную систему для медиакаталога. Сравнить TF-IDF, SVD и item-based ALS с бейзлайном «популярное» на реальных данных. Измерить качество ранжирования, покрытие каталога и разнообразие выдачи.

Результат. В тесте на 116 пользователях популярное лидирует по NDCG@10 (0,3338). ALS получила 0,3282 и показала 207 разных фильмов против 71 у бейзлайна. У 88 пользователей до даты отсечения нет истории, поэтому для них выдачи совпали. Разбор по длине истории приведён на с. 4, два примера — на с. 6.

Оценки	Пользователи	Фильмы	Пустые ячейки
100 836	610	9 742	98,3%

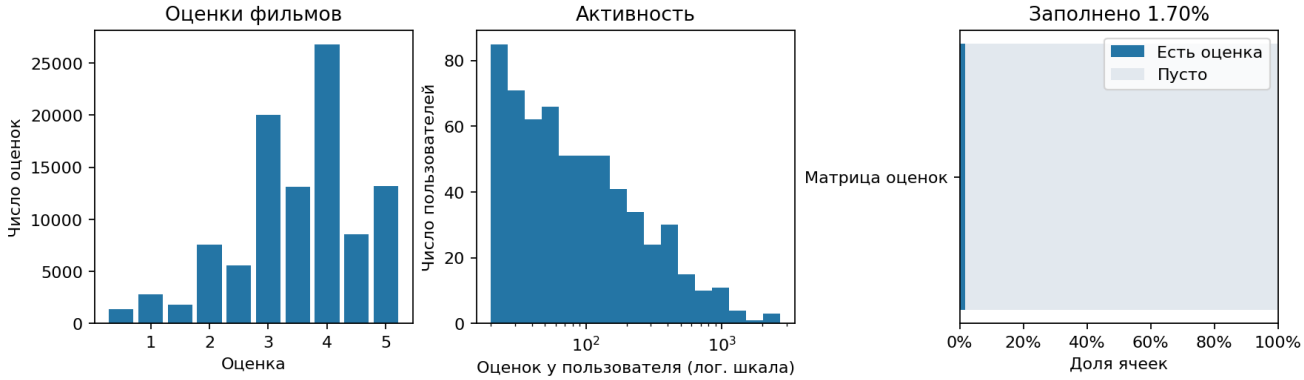


Рис. 1. Распределение оценок, активность пользователей и заполненность матрицы «пользователь × фильм».

У половины пользователей не больше примерно 71 оценки, у четверти — не больше 35, а максимум достигает 2 698. Поэтому среднее число оценок даёт завышенное представление о длине типичной истории. При заполненности матрицы 1,70% большая часть пар «пользователь × фильм» остаётся ненаблюдаемой.

MovieLens выбран из-за сочетания явных оценок, времени их выставления и метаданных фильмов. Названия и жанры достаточны для простой контентной модели, но передают меньше информации о содержании фильма, чем описание или аннотация.

02 Протокол эксперимента

Один временной порог для всех пользователей — 22.03.2016, 08:26:11 UTC. Обучение использует оценки строго до порога, тест — оценки начиная с порога. Таким образом, при прогнозе для пользователя модель не видит будущих взаимодействий других пользователей.

Обучение	Тест	Общий каталог	Релевантных пар в тесте
80 668	20 168	7 867	8 043

Для всех моделей каталог состоит из 7 867 фильмов, получивших хотя бы одну оценку до порога. Из кандидатов исключаются все фильмы, уже оценённые конкретным пользователем. Ранжируется весь оставшийся каталог. В тесте 1 283 из 9 326 положительных оценок относятся к фильмам вне этого каталога (13,8%). Они учтены отдельно и не входят в знаменатель Recall. Поэтому оценка относится к известным системе фильмам.

Модель	Принцип ранжирования
Популярное	Число обучающих оценок ≥ 4 у фильма.
TF-IDF	Косинусная близость названия и жанров к среднему вектору понравившихся фильмов.
SVD	Предсказанная оценка по явным рейтингам, 50 факторов и 20 эпох.
ALS item-based	32 фактора и 15 итераций на бинарных взаимодействиях. Усредняем сходство кандидата с понравившимися фильмами.

Если истории нет, все модели используют популярное. При наличии истории без оценок ≥ 4 на популярное переходят TF-IDF и ALS. При равном балле порядок задаётся популярностью, затем идентификатором фильма. Параметры моделей и длины списка фиксированы. Случайное зерно — 42.

Precision показывает долю попаданий в топ-K, Recall — долю найденных релевантных фильмов. MAP усредняет точность на позициях попаданий с нормировкой на min(K, число релевантных). NDCG сильнее учитывает верх списка. Релевантность бинарная. Сначала считаем метрики для каждого пользователя, затем берём среднее.

03 Качество ранжирования

При K = 10 популярное оказалось первым по всем четырём метрикам на общей выборке. В среднем его список содержит около трёх фильмов, которым пользователь позже поставил ≥ 4.

Модель	Precision@10	Recall@10	MAP@10	NDCG@10
Популярное	0,2974	0,0738	0,2263	0,3338
TF-IDF	0,2802	0,0669	0,2127	0,3138
SVD	0,2888	0,0677	0,2151	0,3213
ALS item-based	0,2931	0,0712	0,2203	0,3282

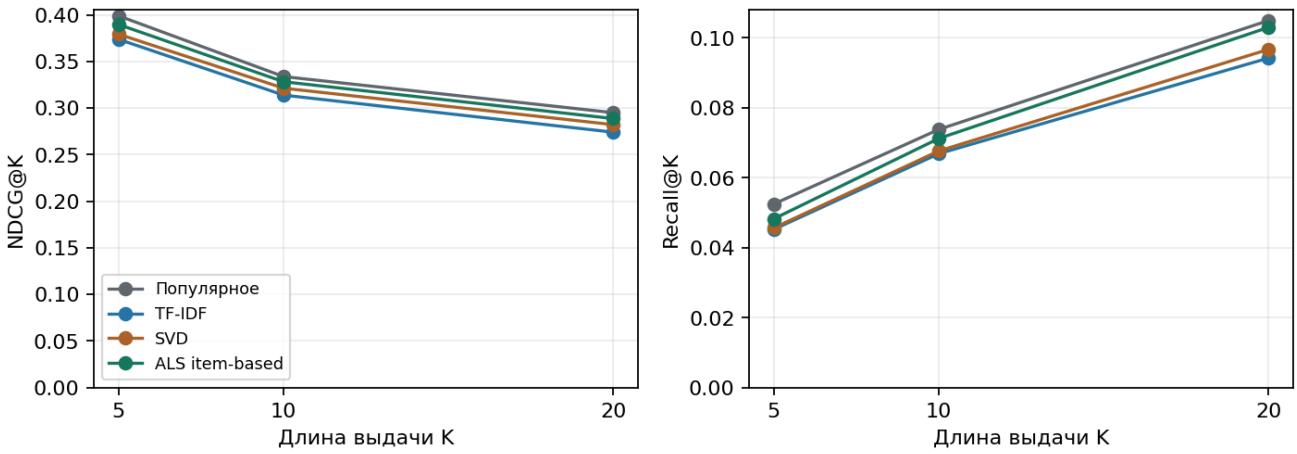


Рис. 2. NDCG и Recall в зависимости от длины выдачи. Ось Y начинается с нуля.

У популярного Recall растёт с 0,0525 при K = 5 до 0,1050 при K = 20, а Precision падает с 0,3828 до 0,2448. Дополнительные позиции дают больше попаданий, но средняя доля попаданий в расширенном списке ниже. NDCG нормируется отдельно для каждого K, поэтому его снижение не означает, что первые пять позиций изменились.

При K = 20 разрыв по Recall между популярным и ALS — около 0,002. Длина выдачи меняет баланс точности и полноты, однако в среднем по 116 пользователям лидер на трёх проверенных K остаётся тем же.

04 Качество по длине истории

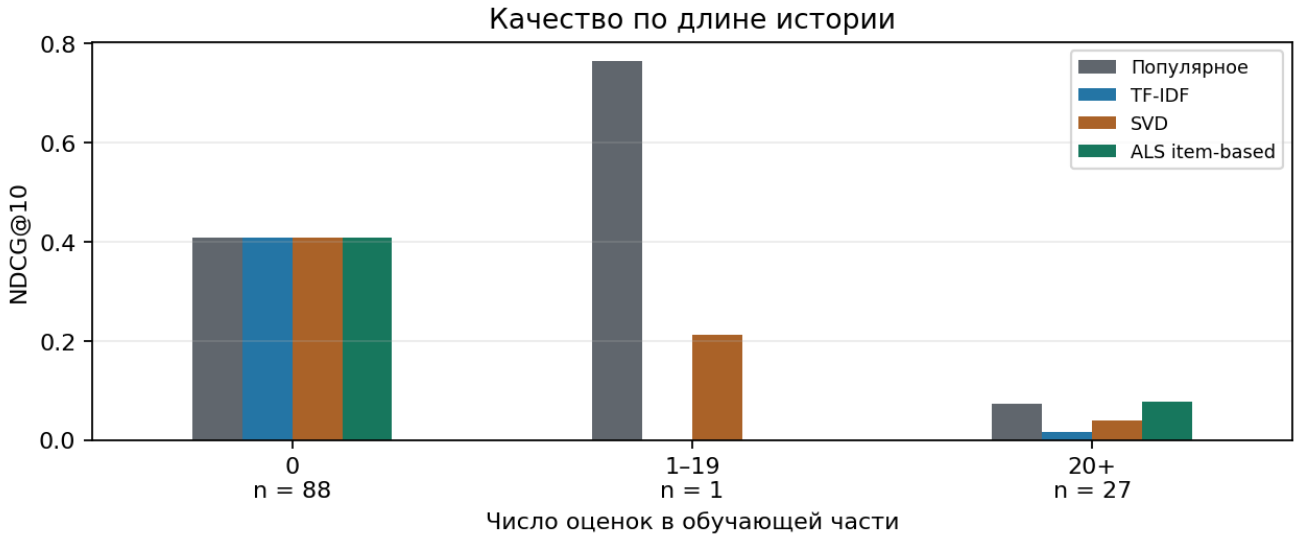


Рис. 3. NDCG@10 по числу оценок до временного порога. Под числом оценок указано число пользователей.

У 88 из 116 пользователей (75,9%) нет истории до порога. Все четыре модели дают им одинаковую выдачу и NDCG@10 = 0,4091. Поэтому общая метрика в основном описывает этот сценарий. В группе 1–19 оценок всего один пользователь, и её результат нельзя обобщать.

У 27 пользователей с 20+ оценками ALS имеет NDCG@10 = 0,0767 против 0,0722 у популярного. При этом Recall@10 у ALS ниже (0,0355 против 0,0412). ALS немного лучше располагает попадания в начале списка по NDCG, а популярное находит большую долю релевантного.

Модель	Δ NDCG, все	95% интервал	Δ NDCG, 20+	95% интервал
TF-IDF	-0,0199	-0,0407…-0,0051	-0,0572	-0,1160…-0,0130
SVD	-0,0125	-0,0309…0,0007	-0,0331	-0,0904…0,0117
ALS item-based	-0,0056	-0,0296…0,0166	0,0044	-0,0806…0,0846

Интервалы получены парным бутстрэпом по пользователям, 2 000 повторов. Для ALS оба интервала включают ноль, поэтому преимущество в активной группе по этой выборке не установлено. У групп различаются и тестовые цели: медиана релевантных фильмов равна 42 без истории и 13 при 20+ оценках. Сравнивать модели надёжнее внутри одной группы.

05 Покрытие и разнообразие

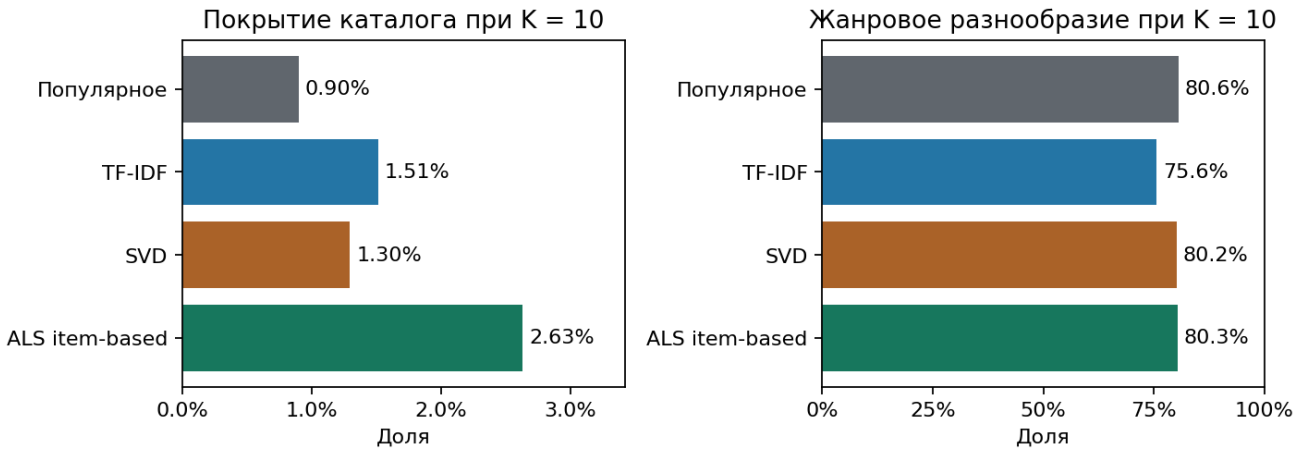


Рис. 4. Покрытие общего каталога и среднее попарное жанровое разнообразие при K = 10. Масштабы осей различаются.

Модель	Фильмов из 7 867	Вне популярных 10%	Разнообразие
Популярное	71	0,0%	0,806
TF-IDF	119	19,0%	0,756
SVD	102	1,6%	0,802
ALS item-based	207	11,8%	0,803

Покрытие — доля фильмов, появившихся хотя бы в одной выдаче. ALS показала 207 разных фильмов, популярное — 71. По жанровому разнообразию ALS близка к бейзлайну. Это два отдельных эффекта: разные пользователи могут получить больше разных фильмов, даже когда разнообразие внутри каждого списка почти не меняется.

TF-IDF даёт больше фильмов за пределами верхних 10% каталога по популярности (19,0% выдачи), но его списки наиболее однородны по жанрам (0,756). Разнообразие измерено средним расстоянием Жаккара между наборами жанров двух фильмов. Пары без жанровой разметки пропущены.

Выдача TF-IDF согласуется с риском сужения рекомендаций вокруг уже известных жанров и серий. Одноразовая офлайн-проверка показывает однородность списков. Чтобы измерить изменение интересов со временем, потребовались бы последовательные показы и реакции пользователей.

06 Разбор двух выдач

Для иллюстрации взяты два случая с наибольшей разницей NDCG@10 между ALS и популярным в противоположных направлениях. Типичное качество отражено в таблице метрик по всем пользователям.

Пользователь 601 · 27 оценок в истории

В истории есть высокие оценки у Finding Nemo и The Incredibles. ALS поставила Shrek на первое место, Good Will Hunting — на второе, V for Vendetta — на третье, The Sixth Sense — на четвёртое. Все четыре фильма получили позднее ≥ 4. У популярного было одно попадание, на девятой позиции. В этом случае сходство фильмов по аудитории подняло релевантные позиции в разных жанрах.

Пользователь 15 · 16 оценок в истории

В обучении пользователь поставил Lethal Weapon 2 пять звёзд. Первые три позиции TF-IDF заняли другие части серии Lethal Weapon. Среди них нет тестовых попаданий. У ALS тоже нет попаданий в топ-10. Популярное поставило The Shawshank Redemption, Pulp Fiction и Forrest Gump на первые три позиции, и все три получили ≥ 4 в тесте. Всего у популярного семь попаданий.

Пользователь	Популярное	TF-IDF	SVD	ALS item-based
601	0,0663	0,0000	0,0636	0,5638
15	0,7656	0,0000	0,2122	0,0000

Таблица показывает NDCG@10. Фильмы без поздней оценки ≥ 4 отмечены как непопадания. По этим данным нельзя сказать, что пользователь их посмотрел и отверг.

07 Заключение и воспроизводимость

В общем временном тесте популярное выигрывает по NDCG@10. Для пользователей без истории оно уже даёт ту же выдачу, что и остальные модели. У пользователей с 20+ оценками ALS чуть выше по NDCG, но интервал разницы широкий. Измеренное преимущество ALS — охват: 207 фильмов вместо 71 при близком среднем NDCG.

Смена метода зависит от цели. Для приоритета точности в проверенном сценарии популярное остаётся отправной точкой. Для расширения охвата стоит отдельно проверить ALS на большей выборке пользователей с историей. TF-IDF на названиях и жанрах давал мало попаданий в этой группе и иногда заполнял верх списка частями одной серии.

Границы выводов

Выводы относятся к одному архиву MovieLens и одному временному порогу. У оценок нет логов показов. Пользователь мог не оценить фильм, потому что не увидел его. В тесте оценивались известные к моменту отсечения фильмы, поэтому результат не описывает холодный старт фильма. Офлайн-метрики не измеряют реальное время просмотра.

Повторный запуск

```
python recsys.py --dataset movielens --model all --k 5 10 20 --evaluate
```

Артефакты прогона сохранены в results. metrics.csv содержит метрики по моделям, K и сегментам. В recs.json сохранены выдачи с отметками попаданий. summary.json содержит состав выборок, интервалы и контрольную сумму архива. В practice7.ipynb приведены таблицы, графики и пояснения.

Источник

Harper F. M., Konstan J. A. The MovieLens Datasets: History and Context. ACM TiiS, 2015. DOI 10.1145/2827872. Архив MovieLens Latest Small, GroupLens.

Описание датасета и условия использования